DOCUMENTATION SAS
https://documentation.sas.com/doc/en/statug/15.2/statug_logistic_examples01.htm

https://www.math.univ-toulouse.fr/~besse/wikistat/pdf/st-scenar-app-visa.pdf

DROCOURT :
http://data.mining.free.fr/cours/deroulement.pdf

EXEMPLE – MEMEOIRE :
HTTPS://WWW.LADISSERTATION.COM/HISTOIRE-ET-G%C3%A9OGRAPHIE/HISTOIRE-CONTEMPORAINE/CAS-PRATIQUE-ELABORATION-DUN-MOD%C3%A8LE-DE-CR%C3%A9DIT-SCORING-97809.HTML

https://od-datamining.com/mtheme_knowledgebase-section/sas-et-r-explique-a-ma-fille/1fille/

https://od-datamining.com/knwbase/representer-graphiquement-la-repartition-dun-score/

http://nicolasarnoult.free.fr/mapage/scoring-arnoult-issaad-et-moro.pdf

Mise en œuvre d'un scoring

Présentation du contexte

L' ETUDE : LE SCORING

Pourquoi un Scoring ?

Quand utilise t-on un Scoring ? Dans quel but ?

Le Scoring est une méthode Statistique qui répond à une problématique très simple. Il consiste à affecter une note « Score » à chaque client ou prospect d'une base de données afin de cibler et prospecter avec une meilleure efficacité. Ce score est calculé à partir des variables disponibles de la base de données.

On applique généralement cette méthode afin de trouver les meilleures adresses susceptibles de répondre positivement à une offre marketing particulière. Pour cela, on va dans un premier temps élaborer le profil de notre clientèle cible puis trouver une formule de score afin de « noter tous les clients » de la base de données par rapport aux variables caractérisant notre population cible.

Présentation du contexte : Une entreprise a envoyé un mailing à un représentatif de sa clientèle, soit 39 779 clients. Le but de cette étude est d'analyser le profil des répondants à l'offre marketing et de trouver la formule de score permettant de « noter » l'ensemble des clients de l'entreprise afin de cibler au mieux les personnes répondant positivement à l'offre commerciale.

Description de la table de données :

	Intitulé de la variable	Libellé de la variable	Type de variable	Modalités de la variable
Variable à expliquer	*RETOUR*	*A répondu au mail du 16/04/2003*	*Binaire*	*OUI/NON*
Variables explicatives	AGE	Age du client	Continu	[18 ;19 ;20 ;…;75]
	BUY6	Nombre de commandes passé dans les 6 derniers mois	Continu	0 ;1 ;2 ;…
	BUY12	Nombre de commandes passées dans les 12 derniers mois	Continu	0 ;1 ;2 ;…
	BUY18	Nombre de commandes passées dans les 18 derniers mois	Continu	0 ;1 ;2 ;…
	COA6	Changement d'adresse	Binaire	OUI/NON
	FICO	Revenus financiers	Continu	[565 ;…;810]

	INCOME	Revenu	Continu	[1 500;…;12 800]
	LOC	Localité	Chaîne de caractères	A ;B ;C ;…;H
	MARRIED	Situation familiale : Marié/Pas marié	Binaire	OUI/NON
	OWNHOME	Propriétaire ou non	Binaire	OUI/NON
	SEX	Civilité du client	Chaîne de caractères	M/F
	VALUE24	Montant des commandes sur 24 mois	Continu	[60 ;…;1 317]

Tableau 1 : Présentation du fichier d'étude

ETAPE 2

Exploration des données

1/ Analyse univariée des données

La première étape de toute investigation dans les données est l'examen des statistiques univariées des variables. Elle permet :

- De repérer d'éventuelles données aberrantes, extrêmes, manquantes,…
- De donner un ordre de grandeur des données dont on dispose.
- De voir comment on peut regrouper en classes les variables continues.

Ex : Avec la variable SEX de notre fichier d'étude :

SEX	Frequency	Percent	Cumulative Frequency	Cumulative Percent
F	18516	46.62	18516	46.62
M	21205	53.38	39721	100.00
Frequency Missing = 58				

Tableau 2 : tri à plat de la donnée Sexe

Ici, on constate que la variable SEX n'est pas renseignée pour 58 enregistrements.

Cette variable va donc être recodée de la manière suivante :

- 0 pour non renseignée.
- 1 pour masculin.
- 2 pour féminin.

Ce que vous devez faire :

1- Variables qualitatives : Décrire les recodification éventuelles à mettre en place (vous renseignerez le tableau Codif_VAR_Qualitatives ci-dessous)
2- Variables continues :
   a. Déposez dans ce document le résultat du programme SAS, issu des proc univariate réalisées sur les 4 variables continues. (vous renseignerez le tableau Deciles_VAR_Quantitatives ci-dessous)
   b. Recodez les variables continues en 10 classes, calculez les effectifs suivant les 10 classes (vous renseignerez la colonne « Effectif par décile » dans le tableau Deciles_VAR_Qualitatives ci-dessous)
3- Au vu des effectifs par décile, définir les regroupements éventuels des classes des variables continues. (vous renseignerez le tableau Codif_VAR_Quantitatives ci-dessous)

1- Codage des variables qualitatives

tableau Codif_VAR_Qualitatives

Intitulé de la variable	Codage initial	Recodage	Commentaires
RETOUR	*OUI/NON*		
BUY6	[0 ; 1 ; 2]		
BUY12	[0 ; 1 ; 2 ; 3]		
BUY18	[0 ; 1 ; 2 ; 3 ; 4]		
COA6	OUI/NON		
LOC	A ; B ; … ; H		
MARRIED	OUI/NON		
OWNHOME	OUI/NON		
SEX	F ; M		

2- Codage des variables quantitatives

tableau Deciles_VAR_Quantitatives

Intitulé de la variable	Codage initial	Décile	Effectif par décile
AGE	[18 ; 19 ; 20 ;…; 75]	Décile 1 = [;]	
		Décile 2 = [;]	
		Décile 3 = [;]	
		Décile 4 = [;]	
		Décile 5 = [;]	
		Décile 6= [;]	
		Décile 7 = [;]	
		Décile 8 = [;]	
		Décile 9 = [;]	
		Décile 10 = [;]	
FICO	[565 ; 810]	Décile 1 = [;]	
		Décile 2 = [;]	
		Décile 3 = [;]	
		Décile 4 = [;]	
		Décile 5 = [;]	
		Décile 6= [;]	
		Décile 7 = [;	

		]	
		Décile 8 = [;]	
		Décile 9 = [;]	
		Décile 10 = [;]	
INCOME	[1 500 ; 12 800]	Décile 1 = [;]	
		Décile 2 = [;]	
		Décile 3 = [;]	
		Décile 4 = [;]	
		Décile 5 = [;]	
		Décile 6= [;]	
		Décile 7 = [;]	
		Décile 8 = [;]	
		Décile 9 = [;]	
		Décile 10 = [;]	
VALUE24	[60 ; 1 317]	Décile 1 = [;]	
		Décile 2 = [;]	
		Décile 3 = [;]	
		Décile 4 = [;]	
		Décile 5 = [;]	

	Décile 6= [;]	
	Décile 7 = [;]	
	Décile 8 = [;]	
	Décile 9 = [;]	
	Décile 10 = [;]	

3- Re-Codage des variables quantitatives transformées en 10 classes

Intitulé de la variable	Codage initial	Recodage	Commentaires
AGE	1-2-3-4-5-6-7-8-9-10		
FICO	1-2-3-4-5-6-7-8-9-10		
INCOME	1-2-3-4-5-6-7-8-9-10		
VALUE24	1-2-3-4-5-6-7-8-9-10		

2/ Analyse des liaisons entre les variables explicatives

Ce que vous devez faire :

Vous renseignerez dans cette partie la méthodologie adoptée pour analyser les liaisons entre les variables explicatives et rédigerez vos résultats.

ETAPE 3

Sélection des variables discriminantes

Les tris croisés

L'étape suivante permettant la réalisation d'un Scoring, consiste à construire des tris croisés entre la VAE (Variable A Expliquer) et les variables explicatives qualitatives (les variables quantitatives ayant été transformées) à l'aide du test du khi-deux afin de déterminer s'il existe une liaison ou non entre les variables.

Si toutefois la liaison entre deux variables était vérifiée, l'intensité en serait mesurée avec la statistique V de Cramer.

<u>Le test du khi-deux :</u>

On cherche à vérifier l'indépendance ou non entre deux variables :

<u>1) Hypothèse :</u>

$$\begin{cases} H_0 : \text{X et Y sont indépendants} \\ H_1 : \text{X et Y ne sont pas indépendants} \end{cases}$$

<u>2) Seuil de signification :</u>

$\alpha = 0.05$

<u>3) Statistiques :</u>

La statistique utilisée mesure « l'écart » entre la distribution observée et la distribution théorique attendue.

$$T = \sum_{i,j} \frac{\left(n_{ij} - \frac{n_{i.}n_{.j}}{n}\right)^2}{\frac{n_{i.}n_{.j}}{n}} = \sum_{i,j} \frac{n_{ij}^2}{\frac{n_{i.}n_{.j}}{n}} - n$$

<u>4) *Règle de décision* :</u>

Si p < 0.05 : on s'intéressera à la valeur du V de Cramer, afin de mesurer l'intensité de la relation.

Variable à expliquer * variables explicatives

Variable à expliquer : variable RETOUR

Effectif
Pourcentage Effectif / Total
Pourcentage ligne
Pourcentage colonne

RETOUR * AGE							
RETOUR	AGE						Total
	[18 ; 25]	] 25 ; 35]	] 35 ; 45]	] 45 ; 55]	] 55 ; 65]	] 65 ; 75]	
NON	1018 2,56 2,96 69,3	4890 12,29 14,23 82,35	13153 33,07 38,26 87,05	10731 26,98 31,22 87,78	3431 8,63 9,98 90,55	1153 2,9 3,35 92,31	34376 86,42
OUI	451 1,13 8,35 30,7	1048 2,63 19,4 17,65	1956 4,92 36,2 12,95	1494 3,76 27,65 12,22	358 0,9 6,63 9,45	96 0,24 1,78 7,69	5403 13,58
Total	1469 3,69	5938 14,93	15109 37,98	12225 30,73	3789 9,53	1249 3,14	39779 100

INDICE :	**226,1**	**130,0**	**95,4**	**90,0**	**69,6**	**56,6**

Tableau 3 : Tri croisés entre la variable à expliquer et la variable âge

Ce que vous devez faire :

Effectuez les analyses bivariées entre la VAE et les variables explicatives.
Vous renseignerez ci-dessous le tableau et les conclusions :

Variable	Valeur du khi-deux	Proba	Dépendance Seuil 1%	V de Cramer
AGE				
BUY6				
BUY12				
BUY18				
COA6				
FICO				
INCOME				
LOC				
MARRIED				
OWNHOME				
SEXE				
VALUE24				

En conclusion :

- ✓ Les variables les plus liées à la variable RETOUR :

- ✓ les variables les moins liées à la variable RETOUR :

ETAPE 3

L’analyse du profil des répondants

Le profil des répondants au mailing

Avant même de réaliser la modélisation, nous sommes maintenant en mesure d'établir un profil des répondants au mailing. En effet, à l'aide des tris croisés entre la VAE et les variables explicatives, nous pouvons déterminer quelles sont les modalités qui sont sur ou sous représentées dans chacune des variables vis-à-vis de la variable RETOUR.

Ce que vous devez faire :

Détaillez votre analyse du profil des répondants sur chacune des variables explicatives, en vous inspirant de l'exemple ci-dessous :

L'AGE :

AGE	MODALITES	POIDS	INDICE
	[18 ; 25]	8,4%	226,1
	] 25 ; 35]	19,4%	130,0
	] 35 ; 55]	63,9%	92,9
	] 55 ; 75]	8,4%	66,3

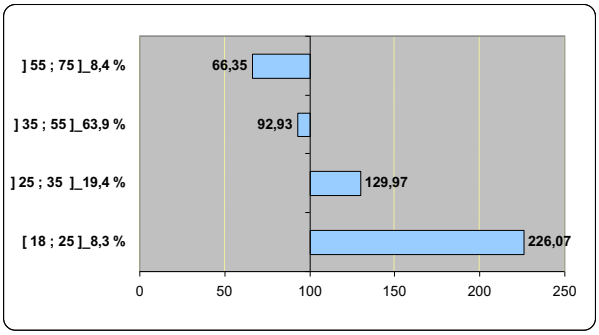

Graphique 1 : Profil des répondants au mailing suivant la variable AGE.

Notre cible est âgée de 18 à 25 ans et dans une moindre mesure de 25 à 35 ans. En effet, ces deux classes d'âges sont sur-représentées parmi les répondants. A l'opposé, un individu âgé de plus de 35 ans a de forte chance d'être exclu de notre cible.

Cette variable est fortement discriminante et fera partie de notre modèle.

- **Nombre de commandes passées durant les 6 derniers mois (BUY6) :**

Graphique 2 : Profil des répondants au mailing suivant la variable BUY6.

Votre commentaire :

.

- **<u>Nombre de commandes passées durant les 12 derniers mois (BUY12) :</u>**

Graphique 3 : Profil des répondants au mailing suivant la variable BUY12.

Votre commentaire :

- **<u>Nombre de commandes passées durant les 18 derniers mois (BUY18) :</u>**

Graphique 4 : Profil des répondants au mailing suivant la variable BUY18.

Votre commentaire :

- **<u>Changement ou non de lieu de résidence durant les 6 derniers mois (COA6) :</u>**

Graphique 5 : Profil des répondants au mailing suivant la variable COA6.

Votre commentaire :

- **Revenu financier (FICO) :**

Graphique 6 : Profil des répondants au mailing suivant la variable FICO.

Votre commentaire :

- **Revenu (INCOME) :**

Graphique 7 : Profil des répondants au mailing suivant la variable INCOME.

Votre commentaire :

- **LOCALITE :**

Graphique 8 : Profil des répondants au mailing suivant la variable LOCALITE.

Votre commentaire

- **MARRIED :**

Graphique 9 : Profil des répondants au mailing suivant la variable MARRIED.

Votre commentaire :

- **OWNHOME :**

Graphique 10 : Profil des répondants au mailing suivant la variable OWNHOME.

Votre commentaire :

- **SEXE :**

Graphique 11 : Profil des répondants au mailing suivant la variable SEXE.

Votre commentaire :

- **Somme totale dépensée sur les 24 derniers mois (VALUE24) :**

Graphique 12 : Profil des répondants au mailing suivant la variable VALUE24.

Votre commentaire :

Ce que vous devez faire :

Faire la synthèse du profil des répondants et du profil des non répondants :

Notre population cible se caractérise de la manière suivante :

- Elle est âgée de XXX à XXXXXX ans.
- Le client a passé au minimum XXXXX commandes sur les XXX derniers mois.
- Il habite les localités XXXXXXXXXXX.
- propriétaire de son logement :
- Ses revenus financiers sont situés entre XXXX et XXXX unités.
- Le montant de ses achats sur les 24 derniers mois est XXXXX €.

En opposition à notre population cible, on trouve :

- Les clients âgés XXXXXXXXXX ans.
- Critère : propriétaires de leur logement.
- Ils habitent les localités ?
- Comportement d’achat ?
- Ils possèdent des revenus financiers :

ETAPE 4

La modélisation

Plusieurs étapes sont nécessaires à l'aboutissement du Score :

- Diviser notre fichier de travail en deux afin d'obtenir un fichier d'apprentissage et un fichier de validation.
- Générer un premier modèle avec toutes les variables.
- Suppression des variables non significatives dans le modèle.
- Création du meilleur modèle et analyse des résultats.

Découpage du fichier

Cette étape consiste à créer deux fichiers à partir de notre fichier de travail :

- Un fichier d'apprentissage qui contient les 2/3 du fichier total. C'est à partir de ce fichier d'apprentissage que nous allons générer un modèle.
- Un fichier de validation qui contient le tiers restant et qui servira à vérifier la robustesse du modèle qui a été généré dans la phase d'apprentissage.

Ces deux fichiers sont créés de manière aléatoire. On obtient un fichier d'apprentissage contenant 26 352 clients et un fichier de validation contenant 13 427 clients.

Exemple d'un CODE SAS :

```
Data M2SAS. mail_apprentissage M2SAS. mail_validation ;set M2SAS. mail_recod ;

If uniform(0)<=0.7 then output M2SAS. mail_apprentissage ; Else output M2SAS. mail_validation ;
Run ;

Proc logistic data=M2SAS.mail_apprentissage descending outmodel= M2SAS.modelV1; class

t_age t_income t_fico t_value24 sex buy6 buy12 buy18 COA6 LOC MARRIED OWNHOME
/*selectionner les variables discriminantes*/.                / param = ref ;

model retour =

t_age t_income t_fico t_value24 sex buy6 buy12 buy18 COA6 LOC MARRIED OWNHOME

/*  /  rsquare selection= stepwise details

sle=0.05
sls=0.01

maxstep = 15 ; */

output out = M2SAS.apprentissage_V1 predprobs = (individual);

run ;
```

Génération d'un premier modèle

Exemple de résultat :

Maximum Likelihood Analysis of Variance			
Source	***DF***	***Chi-Square***	***Pr > ChiSq***
Intercept	1	68.01	<.0001
t_age	3	383.42	<.0001
g_income	4	16.14	0.0028
g_sex	2	17.95	0.0019
MARRIED	1	87.17	<.0001
t_fico	2	52.50	<.0001
OWNHOME	1	126.51	<.0001
t_loc	4	104.53	<.0001
t_buy18	2	137.28	<.0001
t_value24	3	1.72	0.6330
COA6	1	0.05	0.8306
Likelihood Ratio	8,00E+03	8090.51	<.0001

La première donnée à vérifier est la validation globale du modèle. Elle est mesurée grâce au test du ratio de vraisemblance (Likelihood Ratio) : le test révèle l'acceptation du modèle.

Cependant, certaines variables ne sont pas significatives dans notre modèle. En effet, le test du khi-deux, décrit précédemment, nous permet d'affirmer que les variables t_value24 et COA6 n'ont pas d'importance dans la relation que nous modélisons. Le test du khi-deux nous donne des résultats très largement supérieur à 0.05. L'hypothèse d'indépendance entre ces variables et notre variable à expliquer ne peut pas être rejetée.

Ce que vous devez faire :

Génération d'un nouveau modèle.
Indiquer les variables que vous allez sélectionner et Générer un nouveau modèle à l'aide de SAS.
Renseigner le nouveau tableau de résultats :

Génération d'un second modèle :

	Maximum Likehood Analysis of Variance			
	Source	**DF**	**Chi-Square**	**PR > Chisq**
	Intercept			
Renseignez les noms des variables que vous avez sélectionnées dans votre modèle				
	Likehood Ratio			

Votre commentaire :

Le modèle retenu

	Maximum Likehood Analysis of Variance			
	Source	**DF**	**Chi-Square**	**PR > Chisq**
	Intercept			
Renseignez les noms des variables que vous avez sélectionnées dans votre modèle				
	Likehood Ratio			

Calcul de la note de score

Exemple de résultats d'un modèle généré :

Analysis of Maximum Likelihood Estimates					
Parameter		Estimate	Standard error	*Chi-Square*	*Pr > ChiSq*
Intercept		B0 = 1,4772	0,0375	1554,21	<,0001
t_age	[18 ; 25]	B1 = -0,9064	0,0576	247,47	<,0001
	] 25 ; 35]	B2 = -0,2171	0,042	26,74	<,0001
	] 35 ; 55]	B3 = 0,3479	0,0322	116,65	<,0001
	] 55 ; 75]	B4 = -(B1+B2+B3)			
MARRIED	NON	B5 = 0,2003	0,021	90,99	<,0001
	OUI	B6 = -B5			
t_fico	< 670	B7 = -0,2094	0,0306	46,69	<,0001
	< 718	B8 = -0,00869	0,0254	0,12	0,7321
	< 810	B9 = -(B7+B8)			
OWNHOME	NON	B10 = -0,2345	0,0216	117,77	<,0001
	OUI	B11 = -B11			
t_loc	E : F	B12 = 0,1737	0,0316	30,15	<,0001
	G : H	B13 = 0,1212	0,0393	9,53	0,002
	B	B14 = 0,0615	0,0393	2,45	0,1175
	A	B15 = -0,003	0,0581	0	0,9588
	C : D	B16 = - Σ(B12-B15)			
t_buy18	0	B17 = 0,4319	0,029	221,64	<,0001
	1	B18 = -0,3937	0,0317	1,45	0,2278
	> = 2	B19 = - Σ(B17-B18)			

A partir des résultats de la proc logistic, le score de chaque individu va être calculé de la manière suivante :

Score = B0 + B1 * (t_age = "[18 ; 25]") + B2 * (t_age = "] 25 ; 35]") + B3 * (t_age = "] 35 ; 55]") + B4 * (t_age = "] 55 ; 75]") +

…+ B15 * (t_buy18 = ">=2").

B4 =-(B1+B2+B3);

ETAPE 5

La validation du modèle

Qualité du modèle

Courbe de Gain

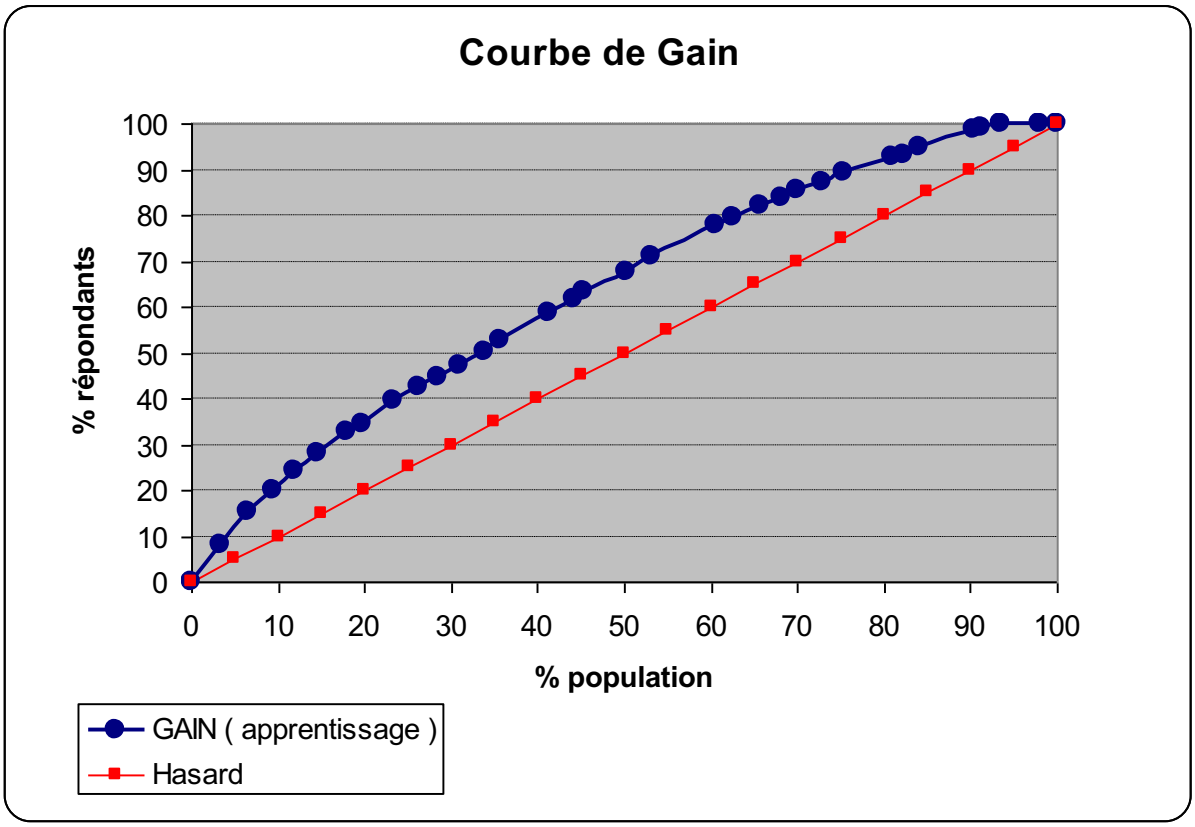

Ce graphique nous présente la courbe de gain de notre modèle. Il s'agit d'un indicateur nous permettant de l'évaluer.

Cette courbe nous renseigne en réalité sur la portée opérationnelle du modèle. Ainsi, à la lecture du graphique, nous pouvons déterminer le pourcentage de répondants que nous allons réussir à cibler en fonction du pourcentage de la population à qui nous allons adresser notre mailing.

Par exemple, ici, avec 10 % de la population, nous allons cibler plus de 20 % des répondants.

Courbe de lift

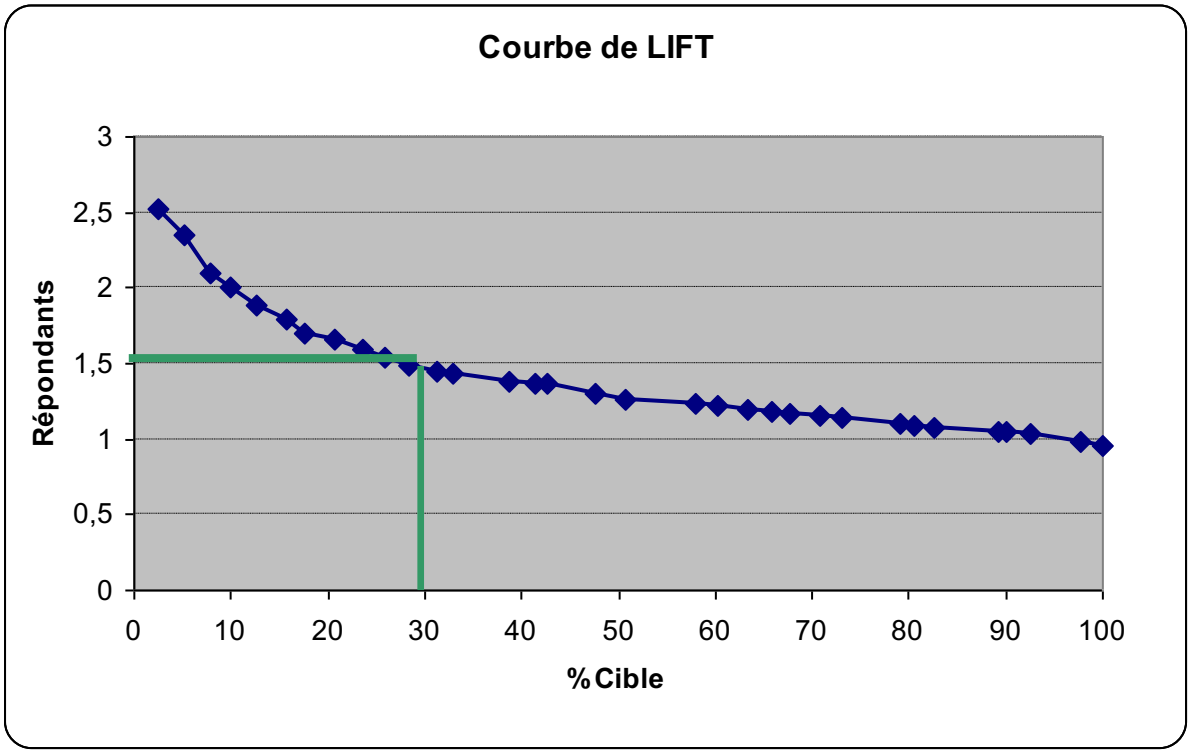

La courbe de Lift correspond au coefficient d'amélioration du rendement par rapport au tirage aléatoire. Dans notre exemple, la sélection par le score de 30 % de la population permet d'obtenir 1.5 fois plus de rendement que le tirage aléatoire.

Remarque : LIFT = (réponses scorées / réponses aléatoires)

Robustesse du modèle

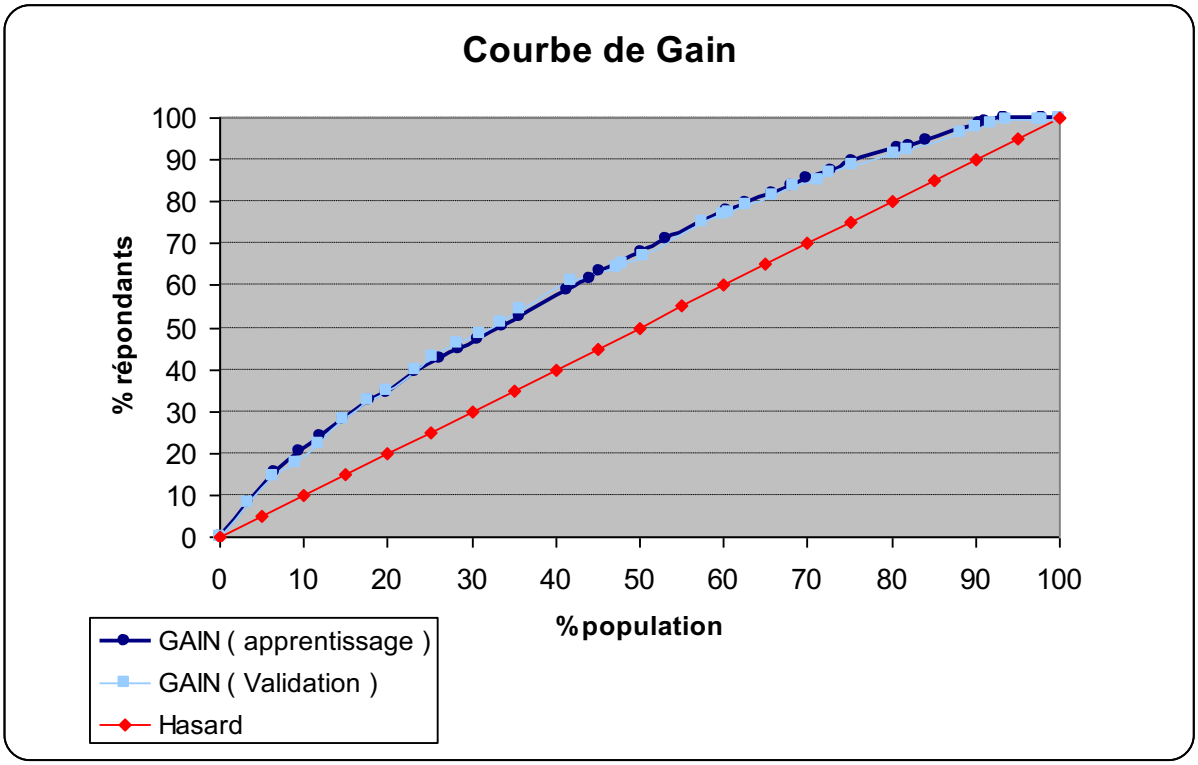

Cette étape consiste à appliquer les résultats de notre modèle sur le fichier de validation. On constate que la courbe de gain du fichier de validation est très proche de celle du fichier d'apprentissage. Ce qui signifie que notre modèle est stable. Il permet d'améliorer significativement les rendements de la campagne marketing et sera donc appliqué lors de la sélection des adresses pour l'envoi de ce mailing.